گزارش کار پروژه چت بات

هدف از این پروژه ایجاد چت بات برای پاسخ به سوالات کاربران با توجه به دو دیتاست customer support و financial است. با توجه به متن تسک ارائه شده چت بات توسعه داده شده باید ویژگی‌های زیر را داشته باشد:

1- از مدل GPT 3.5 Turbo برای پاسخ دهی استفاده شود
2- با فریمورک LangChainپیاده سازی کنید
3- در طول مکالمه از هیستوری چت استفاده کند
4- کاهش اثر Hallucination با راه حلی غیر از fine tuning
5- سوالات مالی و سوالات تخصصی توسط چت بات مربوطه پاسخ داده شود

در ادامه گزارش تمامی ویژگی‌های مذکور بررسی میشوند.

شرح الگوریتم استفاده شده

مدل‌های زبانی بزرگ، که با حجم عظیمی از داده‌های متنی آموزش دیده اند، قادر به تولید متنی هستند که از نظر ظاهری با متن نوشته شده توسط انسان قابل تشخیص نیست. با این حال، این مدل‌ها نیز مستعد ایجاد توهم هستند. توهم در مدل‌های زبانی به معنای تولید متنی است که واقعی یا دقیق نیست. برای جلوگیری از توهم در مدل‌های زبانی روش‌های متعددی پیشنهاد میشود از جمله فاین تیون کردن مدل، قابلیت RAG(Retrieval Augmented Generation) وغیره.

در این پروژه به منظور جلوگیری از توهم از ویژگی RAG با بهره‌گیری از Elastic search استفاده شده است و همچنین برای پیاده سازی آن از فریمورک LangChain استفاده شده است.

معماری سیستم RAG به این صورت است که در ابتدا تمامی اسناد و دیتاست‌ها که در اینجا فایل csv بود به قسمت‌های مشخصی که به آن chunk گفته میشود تقسیم شده و سپس embed میشوند و در یک vector space ذخیره میشوند. Vector space های زیادی وجود دارند از جمله chromaDB، FAISS و یا الستیک سرچ (در این پروژه از الستیک سرچ به منظور سرعت واکشی بالاتر استفاده شده است). پس از ذخیره سازی دیتاست درون vector space، شباهت پرسش کاربر یا وکتورهای embed ذخیره شده از طریق روش‌های مختلف به عنوان مثال semantic Search و یا TF IDF بررسی شده و چانک‌های مربوطه واکشی میشوند. پس از آن Chain مربوطه با توجه به Prompt template و LLM مورد نظر(در این پروژه از GPt 3.5 turbo استفاده شده است) ساخته میشود. در این Chain سوال به همراه contextکه همان چانک واکشی شده است به مدل LLM داده میشود و از LLM خواسته میشود تا با توجه به این کانتکست جواب سوال را بیابد.

در ادامه به شرح جزئی‌تر کد پرداخته میشود.

شرح کد استفاده شده

در تعریف تسک بیان شده است که از دو چت بات استفاده شود و با توجه به پرسش کاربر تشخیص داده شود که مربوط به کدام چت بات است. در این پروژه از آنجا که تمامی دیتاست درون الستیک سرچ ذخیره میشوند نیازی به ایجاد دو چت بات نیست و در

واقع دو دیتاست با یکدیگر تلفیق شده اند. اگر بخواهیم از دو چت بات مجزا استفاده کنیم overhead اضافه بر روی برنامه تحمیل میکنیم. ولی اگر بخواهیم با توجه به پرسش کاربر تشخیص دهیم که از چه چت باتی استفاده شود تنها کافی است از روش های classification به منظور تشخیص نوع سوال کاربر استفاده شود ولی در این پروژه پس از تلفیق و join دو دیتاست نیازی به انجام این کار نیست.

لذا در ابتدا دو دیتاست csv خوانده شده و درون دیتافریم pandas ذخیره شده و سپس تلفیق گشتند و نتیجه به صورت یک فایل json ذخیره شد. قطعه کد زیر نمایانگر همین موضوع است.

```
def load_data_to_json():
  df1 = pd.read_csv ('../dataset/customer_support.csv',encoding='utf-8',sep = ",", header = 0, index_col = False)
  df2 = pd.read_csv ('../dataset/financial.csv',encoding='utf-8',sep = ",", header = 0, index_col = False)

  df = pd.concat([df1, df2], axis=0)

  print(df)
  df.to_json ('joined_datasets.json',orient = "records", date_format = "epoch", double_precision = 10, force_ascii = True, date_unit
```

سپس در تابع index_data فایل json که تلفیق دو دیتاست بود خوانده شده و به منظور انجام RAG به چانک های مشخص تقسیم شده و به صورت امبد شده درون الستیک سرچ ذخیره میشود. قطعه کد زیر نمایانگر همین مورد است. همان طور که در قطعه کد زیر مشخص شده است 6 چانک مرتبط با پرسش کاربر واکشی میشوند.

```
def index_data(data_url):
  metadata = []
  content = []

  f = open(data_url)
  workplace_docs = json.load(f)
  for doc in workplace_docs:
    content.append(doc["fact"])
    metadata.append({
        "question": doc["question"],
    })

  text_splitter = CharacterTextSplitter(chunk_size=100, chunk_overlap=0)
  docs = text_splitter.create_documents(content, metadatas=metadata)
  embeddings = OpenAIEmbeddings(openai_api_key=openai_api_key)
  es = ElasticVectorSearch.from_documents(
      docs,
      elasticsearch_url=url,
      index_name=elastic_index_name,
      embedding=embeddings
  )
  retriever = es.as_retriever(search_kwargs={"k": 6})
  return retriever,es
```

تصاویر زیر نشان دهنده ی اسناد ذخیره شده در الستیک سرچ است.

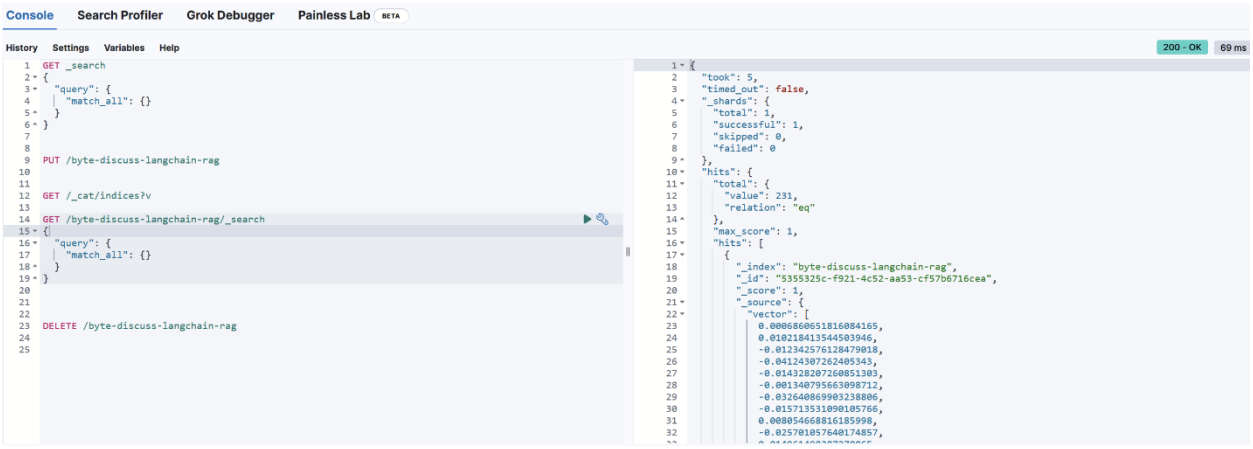

در تابع elastic_chat، chain مربوطه با توجه به Prompt template و LLM ساخته شده و جواب سوال کاربر با توجه به متن واکشی شده، استخراج می شود.

```
def elastic_chat(question):
  r = es.similarity_search(question)
  print(showResults(r))
  template = """Answer in Persian: Answer the question based only on
the following context:
  {context}
  Question: {question}
  """
  prompt = ChatPromptTemplate.from_template(template)

  chain = (
    {"context": retriever, "question": RunnablePassthrough()}
    | prompt
    | ChatOpenAI()
    | StrOutputParser()
  )
  response = chain.invoke(question)
  return response
```

به کمک Flask، api مربوط به این تابع نیز نوشته شده است.

```
@app.route('/elastic', methods=['GET'])
def converstational_chat():
    # try:
        question = str(request.args.get('question'))
        print(question)
        print('\n')
        result = elastic_chat(question)
        print(result)
        final_result = {"result":result}
        return final_result
    # except:
    #     return jsonify({'result':str("An unexpected error happened")})
```

تصاویر زیر نمونه ای از نتایج را نشان میدهد.

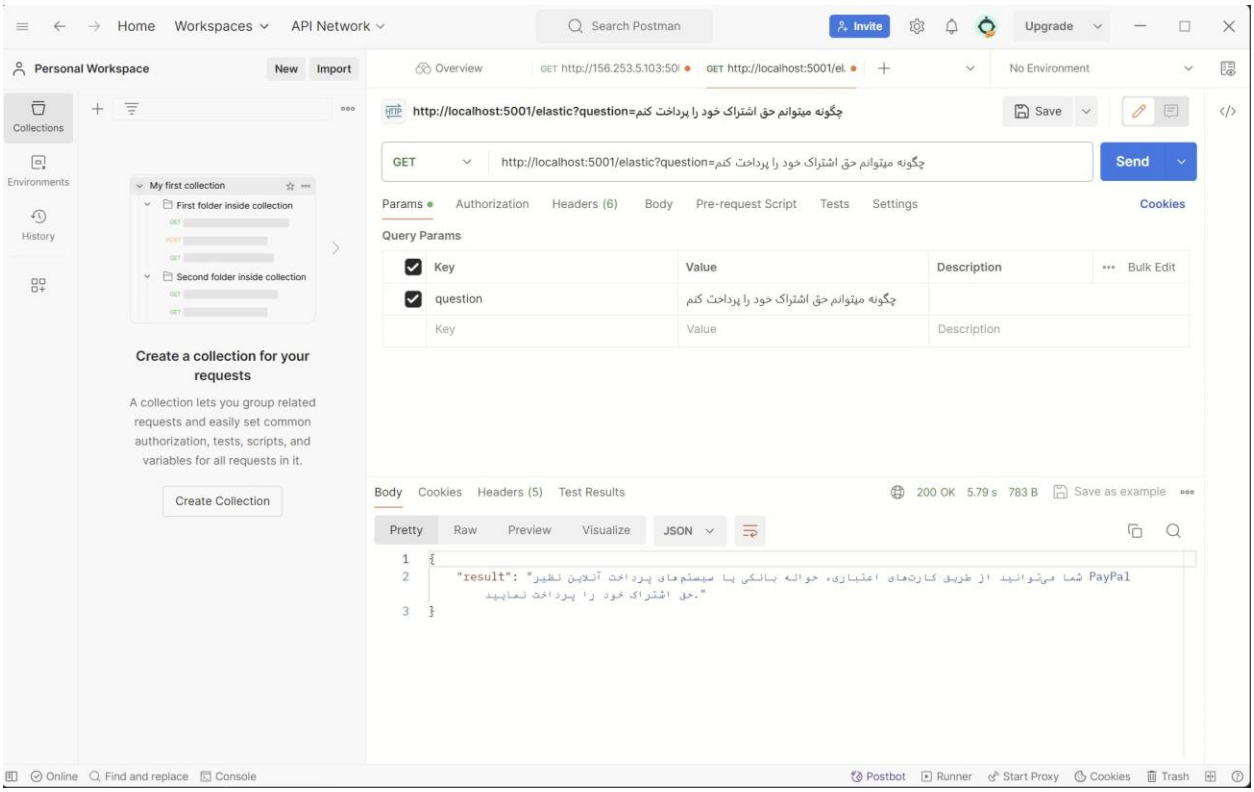

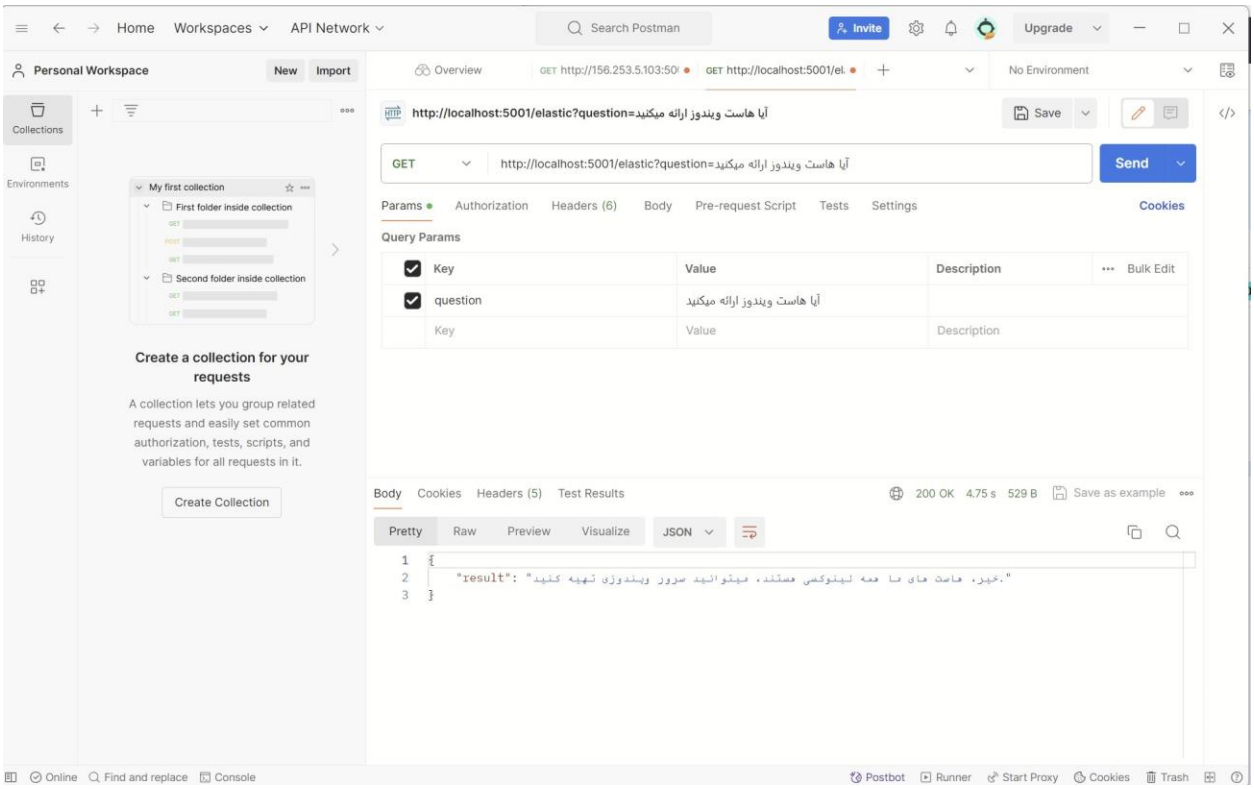
Home
Workspaces
API Network
Search Postman
Invite
Upgrade
Personal Workspace
New
Import
Overview
GET http://156.253.5.103:50
GET http://localhost:5001/el.
No Environment
Collections
Environments
History
http://localhost:5001/elastic?question=آیا هاست ویندوز ارائه میکنید
Save
GET
http://localhost:5001/elastic?question=آیا هاست ویندوز ارائه میکنید
Send
Params
Authorization
Headers (6)
Body
Pre-request Script
Tests
Settings
Cookies
Query Params
Key
Value
Description
Bulk Edit
question
آیا هاست ویندوز ارائه میکنید
My first collection
First folder inside collection
Second folder inside collection
Create a collection for your requests
A collection lets you group related requests and easily set common authorization, tests, scripts, and variables for all requests in it.
Create Collection
Body
Cookies
Headers (5)
Test Results
200 OK
4.75 s
529 B
Save as example
Pretty
Raw
Preview
Visualize
JSON
{
"result": "خیر، هاست های ما همه لینوکسی هستند، میتوانید سرور ویندوزی تهیه کنید."
}
Online
Find and replace
Console
Postbot
Runner
Start Proxy
Cookies
Trash

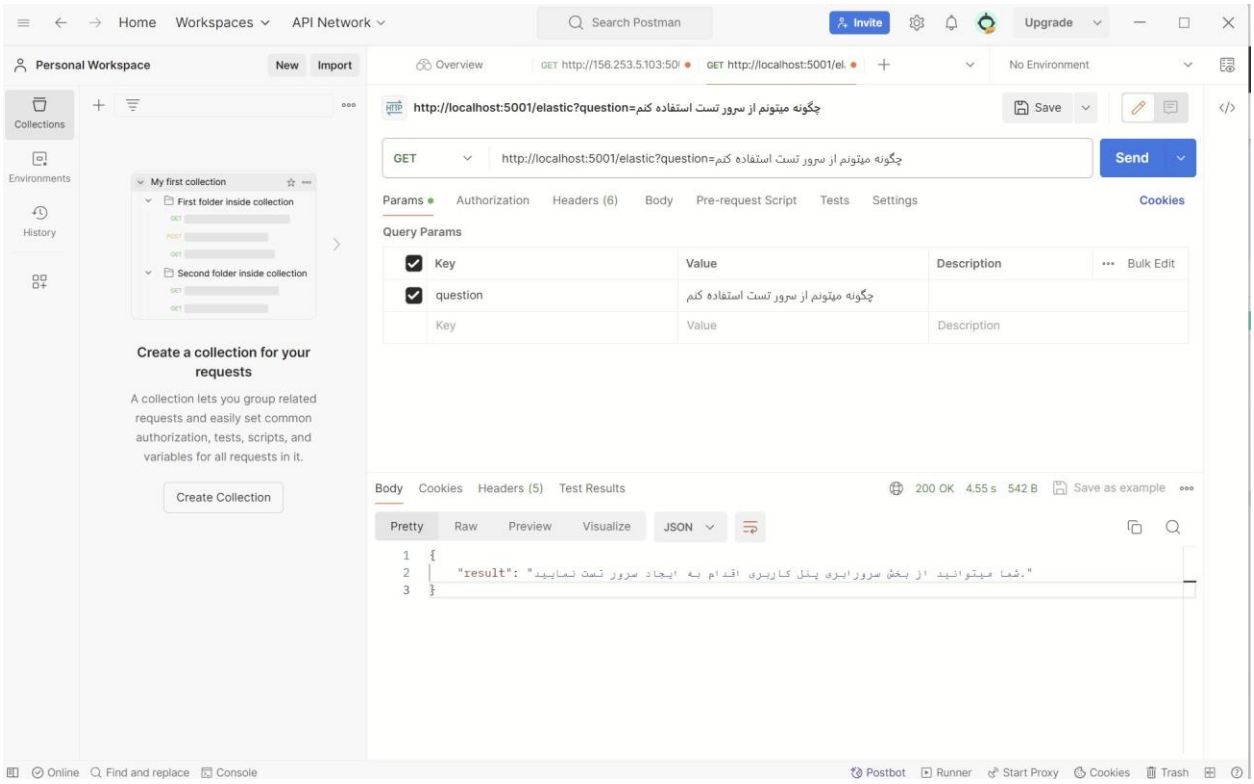
Home
Workspaces
API Network
Search Postman
Invite
Upgrade
Personal Workspace
New
Import
Overview
GET http://156.253.5.103:50
GET http://localhost:5001/el.
No Environment
Collections
Environments
History
http://localhost:5001/elastic?question=چگونه میتونم از سرور تست استفاده کنم
Save
GET
http://localhost:5001/elastic?question=چگونه میتونم از سرور تست استفاده کنم
Send
Params
Authorization
Headers (6)
Body
Pre-request Script
Tests
Settings
Cookies
Query Params
Key
Value
Description
Bulk Edit
question
چگونه میتونم از سرور تست استفاده کنم
My first collection
First folder inside collection
Second folder inside collection
Create a collection for your requests
A collection lets you group related requests and easily set common authorization, tests, scripts, and variables for all requests in it.
Create Collection
Body
Cookies
Headers (5)
Test Results
200 OK
4.55 s
542 B
Save as example
Pretty
Raw
Preview
Visualize
JSON
{
"result": "شما میتوانید از بخش سرورابری پنل کاربری اقدام به ایجاد سرور تست نمایید."
}
Online
Find and replace
Console
Postbot
Runner
Start Proxy
Cookies
Trash

پیاده‌سازی ویژگی حفظ تاریخچه گفتگو

به منظور حفظ تاریخچه ی گفتگو از دیتابیس PostgreSQL و همچنین استفاده از پرسش و پاسخ های قبلی در prompt ورودی به مدل استفاده شده است. برای همین منظور یک table با نام chat در postgresql ساخته شده است که شامل دو فیلد user_id و همچنین chat_history است. در این پروژه تنها از یک یوزر به نام Farzaneh استفاده شده است.

```
CREATE TABLE chat( pid SERIAL PRIMARY KEY, user_id CHARACTER VARYING, chat_history CHARACTER VARYING);

select * from chat

SELECT chat history FROM chat WHERE user id = 'farzaneh'
```

همچنین از prompt template زیر استفاده شده است.

```
Please just  answer the question in Persian
Start of Conversation History
User: پایتخت ایران کجا است ؟
Chatbot: پایتخت ایران تهران است.

User: جمعیت این شهر چقدر است؟
Chatbot:  جمعیت تهران، پایتخت ایران، تقریباً 9 میلیون نفر است.
[End of Conversation History]

[Current Interaction]
User: سوال آخریم چیه
```

در تابع elastic_chat_history در ابتدا با توجه به user_id مقدار chat history واکشی شده و Prompt مورد نظر ساخته میشود. قطعه کد زیر عملکرد این فانکشن را نشان میدهد.

```python
def chat_history(question):
  history = get_data_from_db("farzaneh")
  primary_question = question
  if len(history) >0 :
    question = history[-1] + "Current Interaction User :"  + primary_question
  else:
    question = "User :"  + primary_question

  print(question)

  r = es.similarity_search(question)
  print(showResults(r))
  template = """Answer in Persian: Answer the question based only on the following context:
  {context}
  Question: {question}
  """
  prompt = ChatPromptTemplate.from_template(template)

  chain = (
    {"context": retriever, "question": RunnablePassthrough()}
    | prompt
    | ChatOpenAI()
    | StrOutputParser()
  )
  response = chain.invoke(question)
  question = question.replace("Start of Conversation History","")
  question = question.replace("Current Interaction","")
  question = question.replace("End of Conversation History","")
```

به منظور بررسی نحوه‌ی عملکرد این تابع به ترتیب سوالات زیر از چت بات پرسیده شد و نتایج مرتبط دریافت گردید. تصاویر زیر این پرسش و پاسخ را نمایش میدهد

1- آیا میتوانم برای سایتم CDN فعال کنم؟
2- چگونه فعال کنم؟
3- مراحلش رو بگو

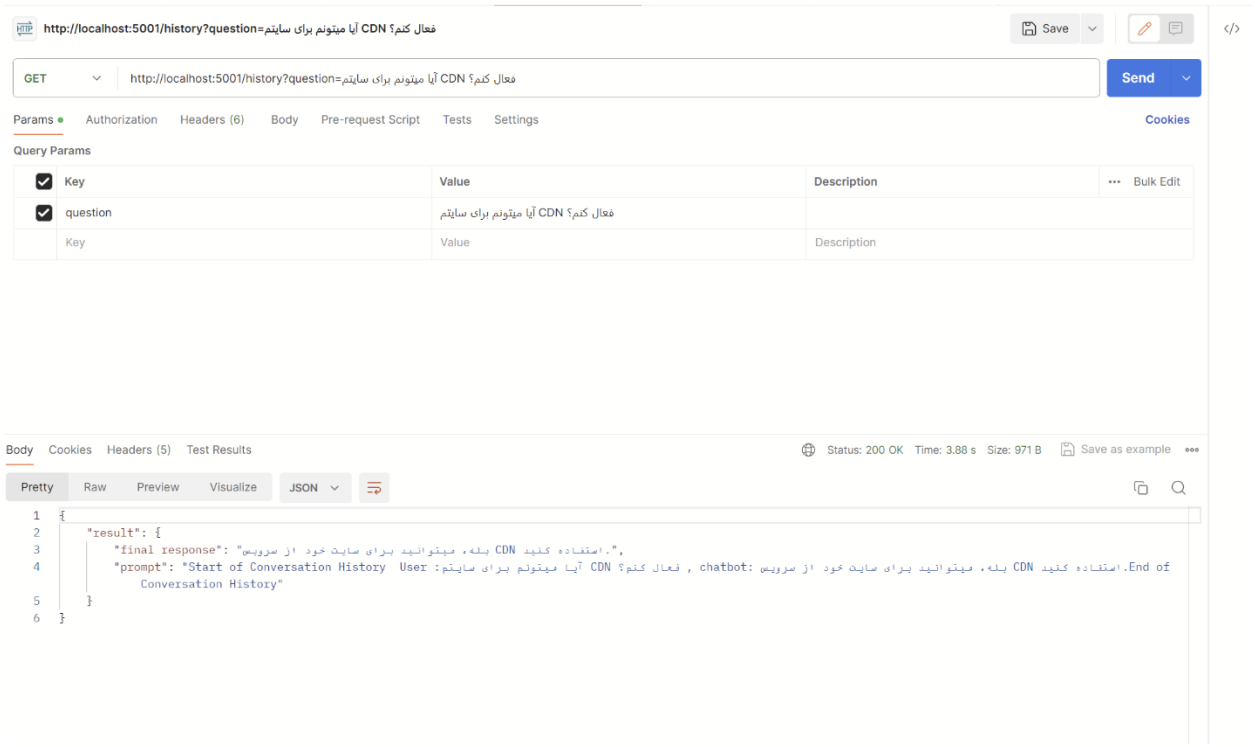
http://localhost:5001/history?question=فعال کنم؟ CDN آیا میتونم برای سایتم
Save
GET
http://localhost:5001/history?question=فعال کنم؟ CDN آیا میتونم برای سایتم
Send
Params
Authorization
Headers (6)
Body
Pre-request Script
Tests
Settings
Cookies
Query Params
Key
Value
Description
Bulk Edit
question
فعال کنم؟ CDN آیا میتونم برای سایتم
Key
Value
Description
Body
Cookies
Headers (5)
Test Results
Status: 200 OK
Time: 3.88 s
Size: 971 B
Save as example
Pretty
Raw
Preview
Visualize
JSON
{
"result": {
"final response": "بله، میتوانید برای سایت خود از سرویس CDN استفاده کنید.",
"prompt": "Start of Conversation History User : آیا میتونم برای سایتم CDN فعال کنم؟ , chatbot: بله، میتوانید برای سایت خود از سرویس CDN استفاده کنید.End of Conversation History"
}
}

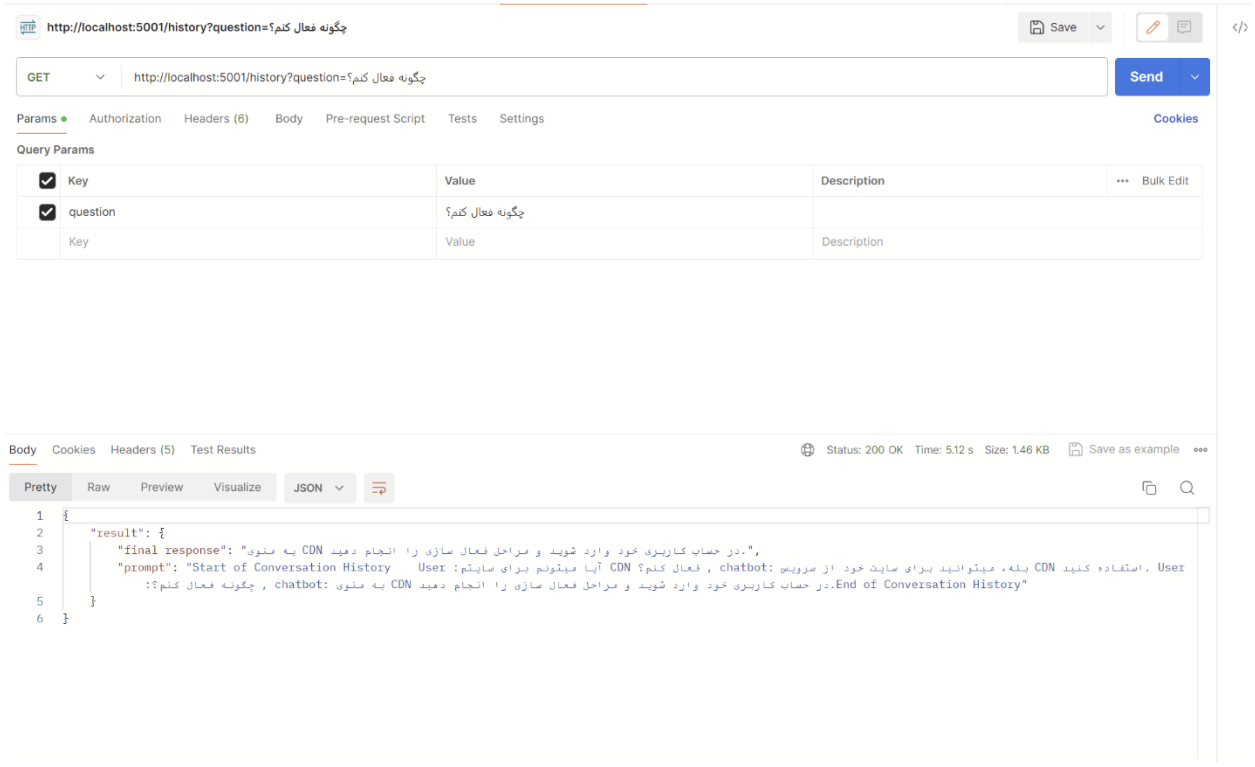
http://localhost:5001/history?question=چگونه فعال کنم؟
Save
GET
http://localhost:5001/history?question=چگونه فعال کنم؟
Send
Params
Authorization
Headers (6)
Body
Pre-request Script
Tests
Settings
Cookies
Query Params
Key
Value
Description
Bulk Edit
question
چگونه فعال کنم؟
Key
Value
Description
Body
Cookies
Headers (5)
Test Results
Status: 200 OK
Time: 5.12 s
Size: 1.46 KB
Save as example
Pretty
Raw
Preview
Visualize
JSON
{
"result": {
"final response": "در حساب کاربری خود وارد شوید و مراحل فعال سازی را انجام دهید CDN به منوی.",
"prompt": "Start of Conversation History User : آیا میتونم برای سایتم CDN فعال کنم؟ , chatbot: بله، میتوانید برای سایت خود از سرویس CDN استفاده کنید. User : چگونه فعال کنم؟ , chatbot: در حساب کاربری خود وارد شوید و مراحل فعال سازی را انجام دهید CDN به منوی.End of Conversation History"
}
}

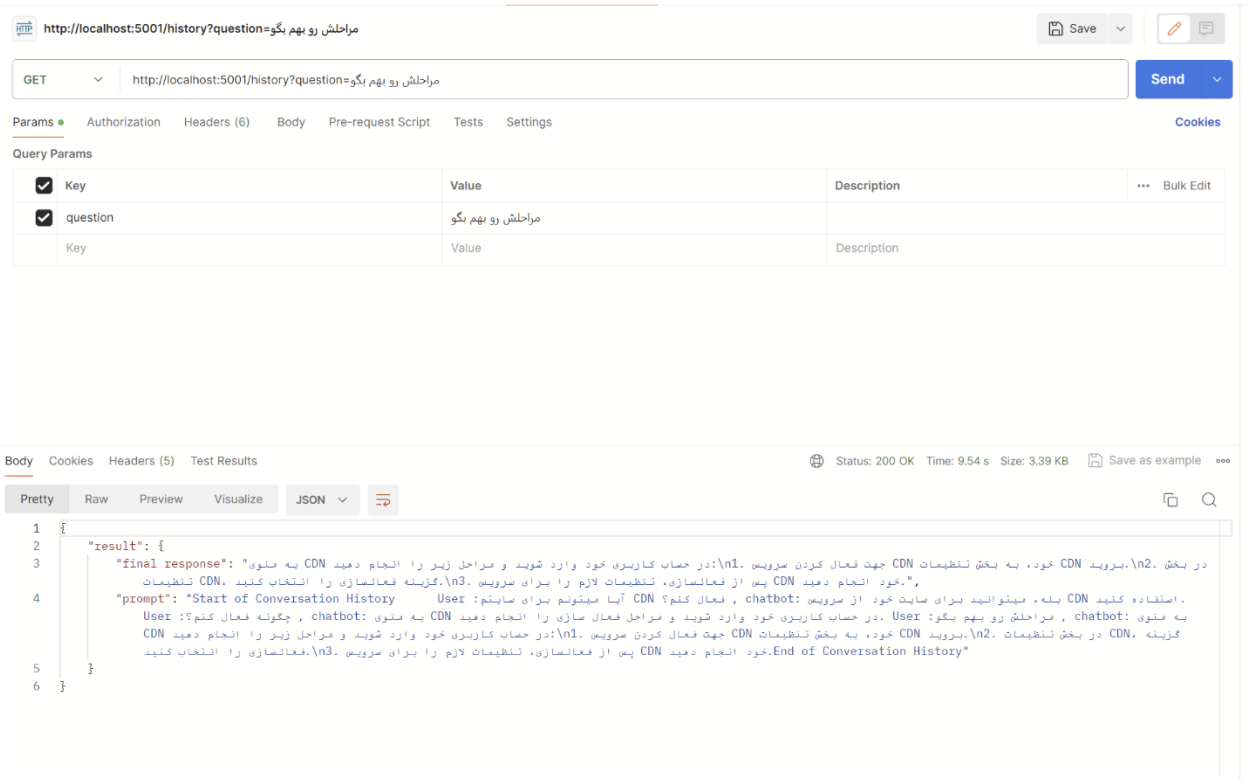

نحوه‌ی استفاده از پروژه

تمامی سرویس های پروژه به صورت داکرایز شده در فایل docker_compose وجود دارد. به منظور استفاده از برنامه تنها کافی است فایل docker compose ران شود و سپس table مورد نظر مطابق با فیلدهای مذکور ساخته شود و سپس apiهای مربوطه فراخوانی شود. Endpoint هر یک از api ها نیز در تصاویر مربوط به هر یک مشخص است.